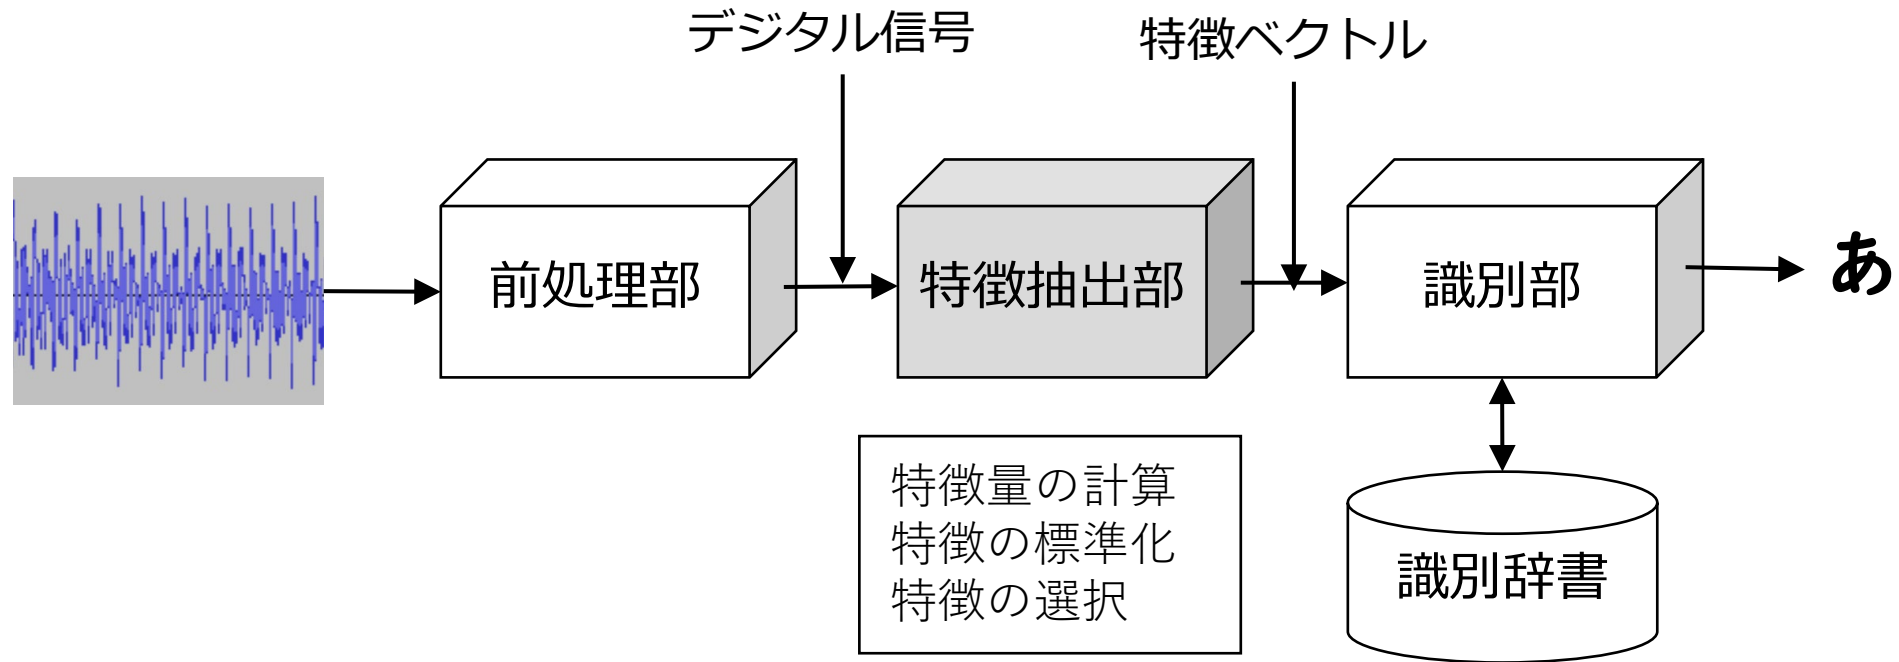



### 3. パターンの特徴を調べよう



## 3.1 変動に強い特徴とは


### 3.1.1 音声の場合

- 音素の違いとは
  - ◆ 声帯を振動の有無  
(パルス波か雑音か)
  - ◆ 声道(口の開き具合・舌の位置など)の変形  
→ 共振周波数の違いが大きな特徴



(a) 発声と調音の仕組み

### 3.1.1 音声の場合

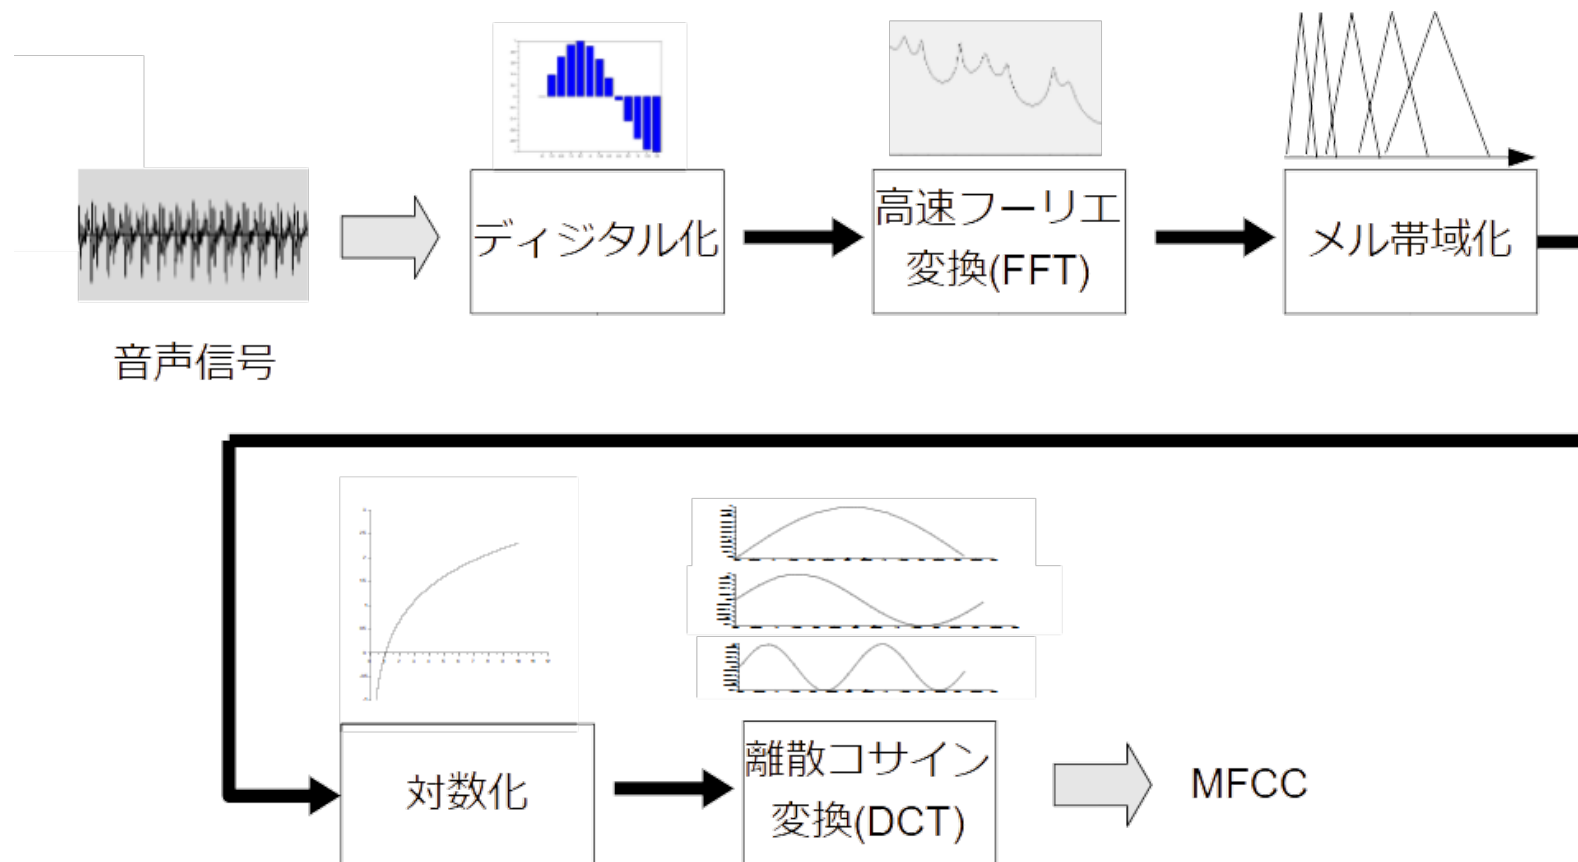


(b) 日本語母音識別のための特徴空間（男性） 軸の単位はHz

### 3.1.1 音声の場合


- MFCC (Mel Frequency Cepstrum Coefficient)

- ◆ スペクトルの概形情報を抽出



## 3.1.2 画像の場合


- 画像の変動
  - ◆ 明るさの変化, 拡大・縮小, 回転など
- SIFT特徴量
  - ◆ 2枚の画像の対応抽出などに有効



## 3.1.2 画像の場合



- Bag of Visual Words

- ◆ SIFT特徴量の似ているベクトルを単語と見なし、その出現頻度を特徴として識別問題に適用



## 3.2 特徴のスケールを揃える

- 各軸で値のスケールが異なる場合
  - ◆ 値の標準化が必要



## 3.2 特徴のスケールを揃える

- スケールの揃え方
  - ◆ 特徴空間の単位超立方体の体積を軸伸縮の前後で一定に保ち、かつパターン相互の距離を最小化  
→ 各軸の分散を等しくする
- 平均値を0にしておく
  - ◆ 学習における初期値の調整が不要
- 標準化の式

$$x'_i = \frac{x_i - m_i}{\sigma_i}$$

$m_i, \sigma_i$ : 軸  $i$  の平均、標準偏差



## 3.3 特徴は多いほどよい

### 3.3.1 偶然に見つかってはまずい

#### (1) 偶然の傾向とは

- 特徴は多いほどよい
  - ◆ 特徴が多くデータ数が少ないと、偶然の傾向が現れるかもしれない
  - ◆ 特徴の次元数が高いほど、偶然の傾向が発見される可能性が高い

### 3.3.1 偶然に見つかってはまずい

#### (2) 学習に必要なパターン数

- 超平面の容量  $2(d+1)$

- ◆  $p(n, d)$  :  $d$ 次元空間上で、適当に配置された $n$ 個のパターンを任意に2クラスに分けたとき、超平面により線形分離できる確率

$$n < 2(d + 1) : p(n, d) \sim 1$$

$$n = 2(d + 1) : p(n, d) = 1/2$$

$$n > 2(d + 1) : p(n, d) \sim 0$$

### 3.3.1 偶然に見つかってしまっはまずい

- 例題3.3

- ◆ データ数: 4

- ◆ 次元数: 1

$$p(4, 1) = 1/2$$

○	○	○	○
○	○	○	×
○	○	×	○
○	○	×	×
○	×	○	○
○	×	○	×
○	×	×	○
○	×	×	×
×	○	○	○
×	○	○	×
×	○	×	○
×	○	×	×
×	×	○	○
×	×	○	×
×	×	×	○
×	×	×	×

(a) データの配置

○	○	○	○
○	○	○	×
○	○	×	○
○	○	×	×
○	×	○	○
○	×	○	×
○	×	×	○
○	×	×	×
×	○	○	○
×	○	○	×
×	○	×	○
×	○	×	×
×	×	○	○
×	×	○	×
×	×	×	○
×	×	×	×

(b) 二つに分離可能

### 3.3.1 偶然に見つかってしまっはまずい



(3) 見つかるはずのないものが見つかった？

- $n \gg 2(d+1)$  のとき
  - ◆ もし、この条件で識別面が見つかったとしたら
    - 偶然には存在しえないものが見つかった
    - その識別面は必然的に存在していた

## 3.2.2 特徴を減らそう

(1) 力業で次元を減らす → 全ての組み合わせを評価する

(2) スマートに主成分分析



# 共分散行列とは

- データの広がりを調べる→共分散行列

- 1次元の場合

- ◆ 平均

$$m = \frac{1}{N} \sum_{x \in \chi} x$$

- ◆ 分散

$$\sigma^2 = \frac{1}{N} \sum_{x \in \chi} (x - m)^2$$

- 多次元の場合

- ◆ 平均ベクトル



$$\mathbf{m} = \frac{1}{N} \sum_{\mathbf{x} \in \chi} \mathbf{x}$$

- ◆ 共分散行列

$$\Sigma = \frac{1}{N} \sum_{\mathbf{x} \in \chi} (\mathbf{x} - \mathbf{m})(\mathbf{x} - \mathbf{m})^T$$

## 共分散行列とは

- 各軸の平均・分散が等しいデータを区別できる



$$\Sigma = \begin{pmatrix} x\text{の分散} & x\text{と}y\text{の相関} \\ x\text{と}y\text{の相関} & y\text{の分散} \end{pmatrix}$$

## 3.2.2 特徴を減らそう

- 主成分分析

- ◆ 共分散行列からデータが広がっている方向（大きな固有値に対応する固有ベクトルの方向）を求める
- ◆ そのうちのいくつかのベクトルで変換行列を構成し、高次元データを低次元データに変換する



## 3.2.2 特徴を減らそう

- 変換行列

- ◆ 変換前の特徴空間におけるパターンの共分散行列 $\Sigma$ の上位 $\tilde{d}$  個の固有値に対応する固有ベクトルを列とする行列

$$A = \begin{pmatrix} a_{11} & \dots & a_{1\tilde{d}} \\ \vdots & \ddots & \vdots \\ a_{d1} & \dots & a_{d\tilde{d}} \end{pmatrix}$$

- 次元数の削減  $Y = XA$

## 第3章 まとめ

- 特徴抽出部の役割
  - ◆ 特徴量の計算
    - 入力の種類および認識対象によって処理が異なる
  - ◆ 特徴の標準化
    - スケールの異なる特徴の識別に対する効果を公平にする
  - ◆ 特徴の選択
    - 実験的に有効な特徴を調べる
    - 低次元に変換する