


5. 誤差をできるだけ小さくしよう

- パーセプトロンの学習規則の欠点
 - ◆ 線形分離不可能である場合には利用できない
 - ◆ 一般に線形分離可能性を事前に確認するのは困難
- 評価関数最小化法
 - ◆ 「誤差」を最小化する
 - ◆ 線形分離不可能な場合にも適用可能



5.1 誤差評価に基づく学習とは

- 学習パターン $\chi = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$
- \mathbf{x}_p ($p = \{1, \dots, n\}$) に対する c 個の識別関数の出力
$$(g_1(\mathbf{x}_p), \dots, g_c(\mathbf{x}_p))^T$$
- \mathbf{x}_p に対する教師ベクトル (教師信号)
$$(b_{1p}, \dots, b_{cp})^T$$
 - ◆ 正解クラスの要素が1、他は0
- 入力パターン \mathbf{x}_p に対する識別関数の出力と、教師信号との誤差 ϵ_{ip} ($i = \{1, \dots, c\}$) が小さくなるように重みベクトル \mathbf{w} を定める

5.1 誤差評価に基づく学習とは

- 誤差: $\varepsilon_{ip} = g_i(\mathbf{x}_p) - b_{ip}$
- ε_{ip} の全クラスに対する二乗和を評価関数 J_p とする

$$\begin{aligned} J_p &= \frac{1}{2} \sum_{i=1}^c \varepsilon_{ip}^2 \\ &= \frac{1}{2} \sum_{i=1}^c \{g_i(\mathbf{x}_p) - b_{ip}\}^2 \\ &= \frac{1}{2} \sum_{i=1}^c (\mathbf{w}_i^T \mathbf{x}_p - b_{ip})^2 \end{aligned}$$

5.1 誤差評価に基づく学習とは

- 全パターンに対する二乗誤差 J

$$\begin{aligned} J &= \sum_{p=1}^n J_p \\ &= \frac{1}{2} \sum_{p=1}^n \sum_{i=1}^c \{g_i(\mathbf{x}_p) - b_{ip}\}^2 \\ &= \frac{1}{2} \sum_{p=1}^n \sum_{i=1}^c (\mathbf{w}_i^T \mathbf{x}_p - b_{ip})^2 \end{aligned}$$

- ◆ この値を最小にする $\mathbf{w}_1, \dots, \mathbf{w}_c$ を求める
- ◆ 以後2クラス問題として、 $g(\mathbf{x}) = g_1(\mathbf{x}) - g_2(\mathbf{x}) = \mathbf{w}^T \mathbf{x}$ とする
- ◆ デモ: <https://playground.tensorflow.org/>

5.2 解析的な解法

- パターン行列 (全特徴ベクトルをまとめた行列)

$$X = (x_1, \dots, x_n)^T$$

- 教師信号ベクトル (全教師信号をまとめたベクトル)

$$b = (b_1, \dots, b_n)^T$$

- 二乗誤差

$$J = \frac{1}{2} \|Xw - b\|^2$$

- 二乗誤差の勾配が0 (極小値) となる w を求める

$$\frac{\partial J}{\partial w} = \underline{X^T (Xw - b) = 0}$$

解くべき式

5.2 解析的な解法

- 解くべき式: $X^T X \mathbf{w} = X^T \mathbf{b}$
- 最小二乗法
 - ◆ $X^T X$ が正則であるとき、以下のように解が求まる

$$\mathbf{w} = (X^T X)^{-1} X^T \mathbf{b}$$

- ◆ 解が求まらない可能性
 - $X^T X$ が正則であるとは限らない
 - d が大きい場合は逆行列を求める計算が大変
- 例題5.1
 - ◆ <https://github.com/MasahiroAraki/SpeechRecognition/blob/master/Python/chap05.ipynb>


5.3 最急降下法

5.3.1 最急降下法による最適化

- w を J の傾きの方向に徐々に修正する

$$w' = w - \rho \frac{\partial J}{\partial w}$$

- 最急降下法のイメージ



5.3.2 Widrow-Hoffの学習規則

- 勾配ベクトルの定義

- ◆ 重みベクトル

$$\mathbf{w} = (w_0, \dots, w_d)$$

の関数 $J(\mathbf{w})$ に対して、勾配ベクトルを

$$\nabla J = \frac{\partial J}{\partial \mathbf{w}} = \left(\frac{\partial J}{\partial w_0}, \dots, \frac{\partial J}{\partial w_d} \right)^T$$

と定義する

5.3.2 Widrow-Hoffの学習規則

- 修正式の導出

$$\frac{\partial J}{\partial \mathbf{w}} = \sum_{p=1}^n \frac{\partial J_p}{\partial \mathbf{w}}$$

$$= \sum_{p=1}^n (\mathbf{w}^T \mathbf{x}_p - b_p) \mathbf{x}_p$$

$$\mathbf{w}' = \mathbf{w} - \rho \frac{\partial J}{\partial \mathbf{w}}$$

$$= \mathbf{w} - \rho \sum_{p=1}^n (\mathbf{w}^T \mathbf{x}_p - b_p) \mathbf{x}_p$$

重みの修正式

- 例題5.3

5.3.3 確率的最急降下法

- 最急降下法の問題点
 - ◆ データ数やパラメータ数が多いと、重み更新に時間がかかる
- 確率的最急降下法
 - ◆ 個々のデータの識別結果に基づき、重みを更新
 - ◆ データが来る毎に学習するオンライン学習が可能
 - 更新式 $w' = w - \rho(w^T x_p - b_p)x_p$

5.3.3 確率的最急降下法

- ミニバッチ法
 - ◆ Widrow-Hoffの学習規則のように、全データの誤差を用いて修正方向を決める方法をバッチ法とよぶ
 - ◆ 確率的最急降下法は1つのデータだけで修正方向を決める（→ 解への収束が安定しない）
 - ◆ これらの中間的手法として、数十～数百程度のデータで誤差を計算し、修正方向を決める方法をミニバッチ法とよぶ
 - ◆ GPU (graphics processing unit) を用いた行列の一括演算と相性がよい


5.4 パーセプトロンの学習規則との比較

5.4.1 パーセプトロンの学習規則を導く

- 更新式の導出

- ◆ オンラインの学習規則において

- 教師信号を正解のときは1、不正解は0とする
- 識別関数の後ろに閾値論理ユニットを置き、出力を0と1に制限する



→ Widrow-Hoffの学習規則はパーセプトロンの学習規則を特別な場合として含む

5.4.2 着目するデータの違い

- パーセプトロンの学習規則
 - ◆ 識別関数、教師信号ともに2値
 - ◆ 全学習パターンに対して、識別関数の出力と教師信号が一致するまで重みの修正を繰り返す
 - ◆ 線形分離不可能な場合は収束しない
 - ◆ 誤識別を起こすデータに着目している
- Widrow-Hoffの学習規則
 - ◆ 識別関数の出力を連続値とし、教師信号との二乗誤差の総和を最小化
 - ◆ 線形分離不可能な場合でも収束が保証されている
 - ◆ 線形分離可能な場合でも誤識別0になるとは限らない
 - ◆ 全データの誤差に着目している